



Universidad Tecnológica de Panamá

Facultad de Ingeniería Eléctrica

Maestría en Ingeniería Eléctrica



Tópicos Especiales II (Machine Learning)
Grupo 1MP215

Aspectos generales del curso

Profesor

Ing. Antony García, M. Sc.

Email: antony.garcia@utp.ac.pa

Descripción General

Duración: 13 semanas (12 semanas de instrucción + 1 semana de proyecto final)

Horario Semanal: 5 horas/semana (3h lunes, 2h viernes)

Formato: Basado en proyectos con tareas semanales

Trabajo en Grupo: Los estudiantes trabajarán en grupos de 2 para todas las tareas y proyectos.

Objetivos del Curso

Al finalizar el curso, los estudiantes serán capaces de:

- ✓ Comprender los conceptos fundamentales y las aplicaciones de machine learning y deep learning.
- ✓ Identificar y diferenciar los principales tipos de problemas y algoritmos de aprendizaje supervisado y no supervisado.
- ✓ Implementar y evaluar modelos de machine learning utilizando Python y bibliotecas relevantes.
- ✓ Aplicar técnicas de preprocesamiento, selección de características y reducción de dimensionalidad.
- ✓ Analizar y comparar el desempeño de diferentes modelos y métricas de evaluación.
- ✓ Desarrollar proyectos prácticos en equipo, integrando conocimientos teóricos y habilidades técnicas.
- ✓ Utilizar herramientas modernas de desarrollo, control de versiones y plataformas colaborativas.



Justificación del Curso

El avance acelerado de la inteligencia artificial y el machine learning está transformando múltiples sectores, desde la industria y la salud hasta la educación y los servicios.

Comprender los fundamentos y aplicaciones de estas tecnologías es esencial para los profesionales modernos, independientemente de su área de especialización. Este curso proporciona una base sólida en los principios y herramientas de machine learning y deep learning, permitiendo a los estudiantes analizar datos, construir modelos predictivos y resolver problemas reales.

Además, fomenta el trabajo colaborativo y el uso de plataformas y herramientas actuales, preparando a los participantes para enfrentar los desafíos tecnológicos del presente y futuro.



Requisitos Previos

✓ **Conocimientos Matemáticos**

- Se recomienda una comprensión básica de álgebra lineal, cálculo, probabilidad y estadística.

✓ **Habilidades de Programación**

- Familiaridad con Python y bibliotecas como NumPy y Scikit-Learn es útil.
- Las tareas y proyectos requerirán scripts en Python.

✓ **Conocimientos Informáticos**

- Usar algoritmos de machine learning requiere cierto nivel de programación.
- El curso está diseñado para ser accesible a una amplia audiencia, con material de apoyo para ayudar a los estudiantes a ponerse al día.
- Los estudiantes con diversos antecedentes en matemáticas y programación pueden tener éxito colaborando en equipos.

Nota Importante

- Este no es un curso de programación; tu código no será calificado.
- Sin embargo, trabajar con datos e interpretar resultados será crítico, y los resultados de tu código serán evaluados.



Herramientas y Plataformas

- **Lenguaje de Programación:** Python
- **Bibliotecas:** NumPy, pandas, Scikit-learn, PyTorch
- **Plataformas:** Jupyter Notebook, Google Colab, Kaggle
- **Control de Versiones:** Git, GitHub



Software Requerido

Editor de Código:

- Visual Studio Code (VS Code) - Recomendado
- PyCharm Community Edition - Opcional

Python:

- Versión 3.8 o superior.

Gestor de Paquetes:

- pip o conda.

Otros:

- Navegador web para acceder a Google Colab o Kaggle.

Rúbricas y Criterios de Evaluación

Rúbrica de Evaluación:

- Asignaciones Semanales (10 en total): 30%
- Proyectos (3 en total): 30%
- Proyecto Final: 40%

• **Escala de Calificaciones:**

- A: 91–100
- B: 81–90
- C: 71–80
- D: 61–70
- F: Menos de 61

Rúbricas y Criterios de Evaluación

Evaluación

- **Asignaciones Semanales:** Evaluadas por corrección, claridad y completitud.
- **Proyectos:** Evaluados por innovación, implementación y presentación.
- **Proyecto Final:** Evaluado por originalidad, profundidad técnica e impacto general.

Definiciones

- **Asignación Semanal:** Una tarea corta diseñada para completarse en unas pocas horas, enfocada en conceptos o habilidades específicas.
- **Proyecto:** Una tarea más extensa que requiere unos días para completarse, integrando múltiples conceptos y aplicaciones prácticas.
- **Proyecto Final:** Una tarea integral y desafiante diseñada para tomar hasta una semana, mostrando el dominio del material del curso.

Integridad Académica y Política de Colaboración

Directrices de Colaboración

- Se anima a los estudiantes a colaborar dentro de sus grupos asignados de 2 personas.
- Se permiten discusiones con otros grupos, pero no deben implicar compartir código o soluciones.

Herramientas Permitidas

- Este curso **promueve el uso de IA generativa** (ChatGPT, Copilot, etc) para el aprendizaje y la mejora de los resultados de los proyectos.
- Se permite el uso de bibliotecas y frameworks externos si se citan adecuadamente.

Herramientas Restringidas

- Está prohibido copiar directamente soluciones de fuentes externas (por ejemplo, repositorios de GitHub).

Originalidad del Código

- Todo el código enviado será revisado por originalidad utilizando herramientas automatizadas.
- El plagio o la similitud excesiva con fuentes externas resultará en sanciones.

Desglose Semanal



Semanas 1–8

Fundamentos de Machine Learning

Desglose Semanal

Semana 1

Lunes (12 de mayo):

Temas

- Introducción a Machine Learning
 - Definición y aplicaciones de machine learning en el mundo real.
 - Breve historia y evolución de machine learning.
- Regresión vs clasificación
 - Diferencias clave y ejemplos de problemas de regresión y clasificación.
 - Casos de uso para cada tipo de problema.
- Aprendizaje supervisado vs no supervisado
 - Descripción general del aprendizaje supervisado con datos etiquetados.
 - Introducción al aprendizaje no supervisado y técnicas de agrupamiento.
 - Ejemplos de aprendizaje supervisado y no supervisado en la práctica.

Tareas: Ninguna

Desglose Semanal

Semana 1

Viernes (16 de mayo):

Temas

- K-Nearest Neighbors (KNN): conceptos, métricas de distancia, demostración con MNIST
 - Explicación del algoritmo KNN y su principio de funcionamiento.
 - Discusión sobre métricas de distancia (por ejemplo, Euclidiana, Manhattan).
 - Demostración práctica utilizando el conjunto de datos MNIST.
- Normalización y estandarización
 - Importancia de la escala de características en machine learning.
 - Diferencias entre normalización y estandarización.
 - Ejemplos prácticos de aplicación de técnicas de escalado.

Tareas: Ninguna

Desglose Semanal

Semana 2

Lunes (19 de mayo):

Temas:

- Correlación de Pearson: comprensión de relaciones entre variables.
- Introducción a modelos lineales.
- Regresión lineal y sus extensiones.
- Regresión logística.
- Técnicas de regularización (L1, L2).
- Clasificador Ridge como ejemplo.

Tareas:

- Asignación 1 asignada.
- Proyecto 1 asignado (entrega: viernes de la semana 5).

Desglose Semanal

Semana 2

Viernes (23 de mayo)

Temas

- Balanceo de clases
 - Importancia del balanceo en problemas de clasificación.
 - Consecuencias del desbalance en el desempeño del modelo.
 - Estrategias comunes:
 - Sobremuestreo de clases minoritarias.
 - Submuestreo de clases mayoritarias.
 - Generación sintética de ejemplos (mención de técnicas como SMOTE).
 - Consideraciones al aplicar estas técnicas: riesgo de sobreajuste y pérdida de información.
- Evaluación de métricas
 - Clasificación
 - Matriz de confusión: Verdaderos Positivos (TP), Falsos Positivos (FP), Verdaderos Negativos (TN), Falsos Negativos (FN).
 - Métricas derivadas:
 - Precisión (Precision)
 - Exhaustividad (Recall)
 - Puntaje F1 (F1-score)
 - Exactitud global (Accuracy)
 - Área bajo la curva ROC (AUC-ROC)
 - Regresión
 - Error Cuadrático Medio (MSE)
 - Raíz del Error Cuadrático Medio (RMSE)
 - Error Absoluto Medio (MAE)
 - Coeficiente de Determinación (R^2)
 - Comparación entre métricas según la sensibilidad a errores grandes o pequeños.
 - Recomendaciones para seleccionar métricas según el contexto del problema.

Tareas: Ninguna

Desglose Semanal

Semana 3

Lunes (26 de mayo)

Temas

- Introducción a modelos probabilísticos.
- Teorema de Bayes y sus aplicaciones.
- Distribuciones de datos.
- Distribución normal.

Tareas

- Asignación 2 asignada.

Desglose Semanal

Semana 3

Viernes (30 de mayo)

Temas

- Modelos Naive Bayes
- Naive Bayes Gaussiano (GNB)
- Naive Bayes Multinomial (MNB)
- Naive Bayes Categórico (CNB)
- Naive Bayes Bernoulli (BNB)

Tareas

- Entrega de la Asignación 1

Desglose Semanal

Semana 4

Lunes (2 de junio)

Temas

- Árboles de decisión
- Entropía
- Índice Gini
- Sobreajuste
- Manejo de datos categóricos y numéricos en árboles de decisión
- Visualización de árboles de decisión

Tareas

- Asignación 3 asignada

Desglose Semanal

Semana 4

Viernes (6 de junio)

Temas

- Feature importance
- Estrategias de pruning
- Técnicas avanzadas de pruning
- Comparación de algoritmos de árboles de decisión

Tareas

- Entrega de la Asignación 2

Desglose Semanal

Semana 5

Lunes (9 de junio)

Temas

- Support Vectors Machine (SVM).
 - Introducción a SVM.
 - Concepto de hiperplanos y límites de decisión.
 - SVM lineal vs no lineal.
 - Funciones kernel (lineal, polinomial, RBF).
 - Margen suave vs margen duro.
- Kernels y márgenes.
 - Ejemplos prácticos del uso de kernels.
 - Visualización de límites de decisión.

Tareas

- Asignación 4 asignada.

Desglose Semanal

Semana 5

Viernes (13 de junio):

Temas:

- GridSearchCV.
 - Automatización de ajuste de hiperparámetros.
 - Ejemplos prácticos con scikit-learn.
- Validación cruzada k-fold.
 - Técnicas de validación cruzada.
 - Evitar sobreajuste con k-fold CV.
- Optimización de hiperparámetros.
 - Técnicas: búsqueda aleatoria vs búsqueda en cuadrícula.
 - Introducción a la optimización bayesiana.

Tareas:

- Entrega de la Asignación 3.
- Entrega del Proyecto 1.
- Proyecto 2 asignado (entrega: viernes de la semana 8).

Desglose Semanal

Semana 6

Lunes (16 de junio)

Temas:

- Random Forests
 - Introducción a métodos de ensamble.
 - Cómo los Random Forests combinan múltiples árboles de decisión.
 - Importancia de características en Random Forests.
 - Manejo del sobreajuste con Random Forests.
- Bagging
 - Concepto de bootstrap aggregation.
 - Ventajas del bagging para reducir la varianza.
 - Comparación de bagging con boosting.

Tareas:

- Asignación 5 asignada.

Desglose Semanal

Semana 6

Viernes (20 de junio)

Temas

- Error out-of-bag
 - Explicación y relevancia en Random Forests.
- Técnicas avanzadas de bagging
 - Método de subespacio aleatorio.
 - Pasting (sin reemplazo).
- Introducción a Extra Trees (Árboles Extremadamente Aleatorizados)
 - Diferencias entre Extra Trees y Random Forests.
 - Casos de uso y ventajas.

Tareas

- Entrega de la Asignación 4.

Desglose Semanal

Semana 7

Lunes (23 de junio)

Temas

- Concepto de boosting y aprendizaje iterativo.
- Adaboost
 - Cómo Adaboost combina clasificadores débiles.
 - Ajuste de pesos para muestras mal clasificadas.
- Gradient Boosting
 - Concepto de descenso de gradiente en boosting.
 - Diferencias entre Adaboost y Gradient Boosting.
- XGBoost (eXtreme Gradient Boosting)
 - Introducción a XGBoost y sus ventajas.
 - Aplicaciones prácticas de XGBoost.

Tareas

- Asignación 6 asignada.

Desglose Semanal

Semana 7

Viernes (27 de junio)

Temas

- Comparación de métodos de ensamble
 - Bagging vs Boosting.
 - Fortalezas y debilidades de cada enfoque.
- Stacking
 - Concepto de apilamiento de modelos.
 - Meta-modelos y su función en stacking.
- Ejemplos prácticos de métodos de ensamble
 - Casos de uso en conjuntos de datos reales.

Tareas

- Entrega de la Asignación 5.

Desglose Semanal

Semana 8

Lunes (30 de junio)

Temas

- Clustering
 - Introducción al clustering y sus aplicaciones.
 - K-means clustering
 - Descripción del algoritmo.
 - Selección del número de clusters (método del codo, puntuación de silueta).
 - Ejemplos prácticos con scikit-learn.
 - DBSCAN (Density-Based Spatial Clustering of Applications with Noise)
 - Concepto de clustering basado en densidad.
 - Ventajas sobre k-means.
 - Casos de uso y limitaciones.

Tareas

- Asignación 7 asignada.

Desglose Semanal

Semana 8

Viernes (4 de julio)

Temas

- PCA (Análisis de Componentes Principales)
 - Concepto de reducción de dimensionalidad.
 - Valores y vectores propios.
 - Visualización de datos de alta dimensión en 2D/3D.
 - Ejemplos prácticos con scikit-learn.
- Feature Engineering
 - Importancia de la selección y extracción de características.
 - Técnicas para crear nuevas características.
- Reducción de dimensionalidad
 - Comparación de PCA con otras técnicas.
 - Casos de uso de reducción de dimensionalidad en machine learning.

Tareas

- Entrega de la Asignación 6
- Entrega del Proyecto 2
- Proyecto 3 asignado (entrega: viernes de la semana 11)

Desglose Semanal

Semanas 9–12

Fundamentos de Deep Learning

Desglose Semanal

Semana 9

Lunes (7 de julio)

Temas

- Introducción a Deep Learning
 - Definición y diferencias clave respecto a machine learning tradicional.
 - Aplicaciones de deep learning en distintos dominios.
- Perceptrones
 - Concepto de perceptrón como bloque básico de redes neuronales.
 - Representación matemática y funciones de activación.
- Funciones de activación
 - Repaso de funciones comunes (sigmoide, ReLU, tanh).
 - Importancia de la no linealidad en redes neuronales.

Tareas

- Asignación 8 asignada.

Desglose Semanal

Semana 9

Viernes (11 de julio)

Temas

- Redes neuronales feedforward
 - Estructura de redes neuronales feedforward.
 - Propagación hacia adelante y actualización de pesos.
- Funciones de pérdida
 - Explicación de funciones de pérdida (MSE, entropía cruzada).
 - Rol de la función de pérdida en el entrenamiento.

Tareas

- Entrega de la Asignación 7.

Desglose Semanal

Semana 10

Lunes (14 de julio)

Temas

- Backpropagation
 - Explicación detallada del algoritmo de retropropagación.
 - Rol de los gradientes y la regla de la cadena en la actualización de pesos.
- Regularización (dropout, batch norm)
 - Técnicas para evitar el sobreajuste en redes neuronales.
 - Explicación de dropout y batch normalization con ejemplos.

Tareas

- Asignación 9 asignada.

Desglose Semanal

Semana 10

Viernes (18 de julio):

Temas

- Ajuste de hiperparámetros
 - Importancia de ajustar hiperparámetros para el rendimiento del modelo.
 - Hiperparámetros comunes en deep learning (learning rate, batch size).
- Schedulers de tasa de aprendizaje
 - Técnicas para ajustar la tasa de aprendizaje durante el entrenamiento.
 - Ejemplos de step decay, exponential decay y tasas de aprendizaje cíclicas.

Tareas

- Entrega de la Asignación 8

Desglose Semanal

Semana 11

Lunes (21 de julio)

Temas

- CNNs: convolución, filtros, pooling
 - Introducción a redes neuronales convolucionales (CNNs).
 - Explicación de capas convolucionales, filtros y mapas de características.
 - Técnicas de pooling (max pooling, average pooling) y su rol en la reducción de dimensionalidad.

Tareas

- Asignación 10 asignada.

Desglose Semanal

Semana 11

Viernes (25 de julio)

Temas

- CNN para clasificación de imágenes
 - Construcción de una CNN para tareas de clasificación de imágenes.
 - Ejemplo práctico usando un dataset (CIFAR-10 o MNIST).
 - Discusión sobre transfer learning para clasificación de imágenes.

Tareas

- Entrega de la Asignación 9.
- Entrega del Proyecto 3.

Desglose Semanal

Semana 12

Lunes (28 de julio)

Temas

- Transfer learning con redes preentrenadas
 - Concepto de transfer learning y sus ventajas.
 - Ejemplos de modelos preentrenados populares (VGG, ResNet).
 - Fine-tuning de modelos preentrenados para tareas específicas.

Tareas

- Ninguna

Desglose Semanal

Semana 12

Viernes (1 de agosto)

Temas

- Test-time augmentation
 - Técnicas para mejorar el rendimiento del modelo durante la inferencia.
 - Ejemplos de aumentaciones (flip, crop).
- Análisis de errores
 - Identificación y abordaje de fuentes comunes de error en modelos de deep learning.
 - Estrategias para mejorar el rendimiento basadas en el análisis de errores.

Tareas

- Entrega de la Asignación 10.

Desglose Semanal

**Semana 13
(Final)**

Lunes (4 de agosto)

Temas

- Presentaciones del proyecto final

Perfil del Docente

Antony Garcia

- Ingeniero Electromecánico egresado de la Universidad Tecnológica de Panamá (UTP).
- M. Sc. en Ingeniería Eléctrica con especialización en Potencia Eléctrica (UTP).
- Estudiante de doctorado en Worcester Polytechnic Institute (WPI)
 - Especialización en Data Science y Computer Science
 - Actualmente trabajando en disertación doctoral en aplicaciones de Inteligencia Artificial en healthcare

Contacto

- Correo electrónico: antony.garcia@utp.ac.pa
- Disponible para consultas por correo o a través del grupo de Teams.